Análisis de Redes Cerebrales fMRI

https://gemini.google.com/app/909101494abfe808

User prompt: Como encuentro redes cerebrales con fmri

Response: Para identificar y extraer redes cerebrales a partir de datos de resonancia magnética funcional en estado de reposo (*rs-fMRI*) o en tarea, existen dos aproximaciones principales: **basadas me hipótesis** (dirigidas por una región de interés) y **basadas me datos** (sin hipótesis previa).

Métodos principales de extracción

Método	Tipo	¿Cómo funciona?	Caso de uso ideal
Seed-to-Voxel (Conectividad Basada en Semilla)	Basado en hipótesis	Se define una ROI (ej. corteza cingulada posterior) y se calcula la correlación temporal de su señal BOLD con todos los demás voxeles del cerebro.	Evaluar redes bien delimitadas como la Default Mode Network (DMN).
ICA Espacial (Spatial ICA)	Basado en datos	Descompone la señal BOLD global en componentes independientes en el espacio, separando redes funcionales del ruido (cardíaco, respiratorio, movimiento).	Identificar múltiples redes simultáneamente sin definir ROIs previas.
Análisis de Grafos & Matriz ROI-to-ROI	Basado en datos / Atlas	Parcela el cerebro usando un atlas (ej. Schaefer, Harvard-Oxford), calcula la matriz de correlación $N \times N$ y aplica métricas topológicas.	Caracterizar propiedades de red global (eficiencia, modularidad, grado).

Pipeline técnico en Python (`Nilearn`)

`Nilearn` facilita la extracción automática de redes mediante atlas predefinidos o descomposición ICA.

```
import numpy as np
from nilearn import datasets, decomposition, input_data, connectome

# 1. Extracción de redes mediante Spatial ICA (CanICA)
canica = decomposition.CanICA(
    n_components=20,
    smoothing_fwhm=6.,
    memory="nilearn_cache",
    random_state=42
)
```

```
canica.fit(func_filenames) # Archivos NIfTI preprocesados
components_img = canica.components_img_ # Mapas NIfTI de las 20 redes

# 2. Extracción mediante Atlas (ROI-to-ROI Connectome)
atlas = datasets.fetch_atlas_schaefer_2018(n_rois=100)
masker = input_data.NiftiLabelsMasker(
    labels_img=atlas.maps,
    standardize=True,
    detrend=True
)

time_series = masker.fit_transform(func_filename)
correlation_measure = connectome.ConnectivityMeasure(kind='correlation')
correlation_matrix = correlation_measure.fit_transform([time_series])[0]
```

Toolboxes recomendados según el flujo de trabajo

- **AFNI:** Comandos `v2s` y `3dGroupInCorr` para análisis interactivo de conectividad basada en semilla, o `3dICA` / interface con Group ICA.
- **CONN Toolbox (MATLAB/SPM):** Pipeline GUI integral para preprocesamiento, deconfounding (CompCor), seed-to-voxel, ROI-to-ROI e ICA de grupo.
- **FSL (MELODIC):** Estándar para descomposición por componentes independientes (*Tensor-ICA* para grupo).

Pasos críticos de preprocesamiento previos al análisis

1. **Deconfounding:** Eliminar señal de sustancia blanca, LCR y parámetros de movimiento (ej. regresión 24-parametrizada o AROMA).
2. **Filtrado temporal:** Aplicar un filtro pasabanda ($0.01\ \text{Hz} - 0.1\ \text{Hz}$) para aislar las fluctuaciones de baja frecuencia características del BOLD en reposo.
3. **Scrubbing / Censurado:** Excluir volúmenes con *Framewise Displacement* (FD) elevado ($> 0.2\ \text{mm} - 0.5\ \text{mm}$).
