Análisis de Rs-fMRI con CONN

https://gemini.google.com/app/1a35330b32051d5a

User prompt: Tengo un grupo de imágenes de resonancia magnética en estado en reposo que puedo estudiar de ellas con la herramienta conn

Response: La caja de herramientas **CONN** (desarrollada por Alfonso Nieto-Castáñón) es una de las plataformas más completas y robustas basadas en MATLAB para el análisis de resonancia magnética funcional en estado en reposo (*resting-state fMRI* o rs-fMRI).

A partir de un grupo de imágenes en estado en reposo, CONN te permite realizar análisis avanzados tanto a nivel de redes cerebrales completas como de regiones específicas. Las principales líneas de estudio que puedes abordar son:

1. Conectividad Funcional Basada en Semillas (*Seed-to-Voxel* y *ROI-to-ROI*)

- **Seed-to-Voxel:** Permite definir una región de interés (ROI) o "semilla" (por ejemplo, la amígdala, el hipocampo o el precúneo) y evaluar la correlación temporal de su señal BOLD con cada vóxel del resto del cerebro. Ideal para probar hipótesis específicas sobre circuitos o redes conocidas.
- **ROI-to-ROI:** Construye una matriz de conectividad entre múltiples regiones predefinidas (utilizando atlas estándar como FSL, Harvard-Oxford, AAL o tus propias máscaras). Es perfecto para estudiar interacciones dentro de circuitos cerrados (como el circuito fronto-parietal o el sistema límbico).

2. Análisis de Componentes Independientes a Nivel de Grupo (*Group-Level ICA*)

- Si prefieres un enfoque guiado por los datos (*data-driven*) sin necesidad de seleccionar una semilla a priori, CONN incluye herramientas de ICA para descomponer la señal cerebral en componentes espaciales independientes.
- Te permite identificar las principales **Redes de Estado en Reposo (RSNs)** —como la Red por Defecto (DMN), la red de saliencia, la red ejecutiva central o redes somato-sensoriales— y evaluar diferencias intergrupales en su topografía espacial o en su amplitud de fluctuación.

3. Teoría de Grafos (*Graph Theory Analysis*)

- CONN incluye un módulo completo de teoría de grafos para modelar el cerebro como una red compleja (nodos = ROIs, aristas = fuerzas de conectividad).
- Puedes calcular métricas topológicas globales y locales para caracterizar la organización cerebral, tales como:
    - **Eficiencia global y local** (integración y segregación de la información).
    - **Camino característico y coeficiente de clustering**.
    - **Centralidad de grado** (*degree centrality*) para identificar nodos clave o "hubs" corticales y subcorticales.

4. Conectividad Funcional Dinámica (*Dynamic FC*)

- Tradicionalmente se asume que la conectividad es estacionaria durante toda la sesión de resonancia. Con el módulo de conectividad dinámica de CONN (basado en ventanas deslizantes o *sliding-window*, y análisis de estados de conectividad), puedes estudiar **cómo fluctúa la conectividad funcional a lo largo del tiempo** y detectar transiciones entre diferentes estados cerebrales.

5. Análisis Estadístico y Covarianzas

- **Comparaciones entre grupos y condiciones:** Evaluar diferencias significativas entre pacientes y controles, o efectos pre/post intervención.
- **Correlaciones paramétricas y no paramétricas:** Relacionar la fuerza de conectividad funcional con variables clínicas, conductuales o puntuaciones de pruebas psicométricas.
- **Control riguroso de ruido (*Denoising*):** Implementa el método **aCompCor** (*CompCor anatómico*) para la regresión de ruido fisiológico (componentes de materia blanca y LCR), control de movimiento por regresión y *scrubbing*, además de filtrado paso-banda.

¿Qué tipo de diseño experimental o hipótesis tienes planteada para este grupo de datos (por ejemplo, comparación entre grupos clínicos, correlación con alguna variable cognitiva o validación metodológica)?

User prompt: Correlación con alguna variable cognitiva

Response: Estudiar la relación entre la conectividad funcional en reposo y las **variables cognitivas** (como cociente intelectual, memoria de trabajo, funciones ejecutivas, velocidad de procesamiento o perfiles de altas capacidades) es una de las aplicaciones más potentes de CONN. Permite pasar de describir cómo está conectado el cerebro a entender **cómo esas diferencias individuales en conectividad predicen o modulan el rendimiento cognitivo**.

En la interfaz de CONN, este proceso se realiza principalmente en el nivel de segundo nivel (*Second-level results*). Los enfoques metodológicos y pasos clave para estructurar este análisis son los siguientes:

1. Preparación de las Variables Cognitivas en CONN

Antes de entrar al módulo de resultados, debes registrar tus variables en la pestaña **Setup -> Covariates (2nd-level)**:

- **Creación de covariables:** Añade una nueva covariable por cada prueba o subescala cognitiva (por ejemplo, `Memoria_Trabajo`, `Velocidad_Procesamiento`, `CI_Total`). Introduce un valor numérico por cada sujeto.
- **Datos faltantes:** Si algún sujeto no completó una prueba específica, CONN permite dejar el valor vacío o NaN, siempre y cuando configures adecuadamente el modelo de diseño.
- **Estandarización:** Es muy recomendable centrar las variables (restar la media) o convertirlas en puntajes Z para facilitar la interpretación de los coeficientes de regresión, especialmente

si vas a incluir interacciones o covariables de confusión.

2. ¿Qué tipos de análisis puedes realizar con variables cognitivas?

A. Conectividad Modulada por Cognición (*Seed-to-Voxel* o *ROI-to-ROI*)

Puedes evaluar si la fuerza de la conectividad funcional entre una región clave (ej. el hipocampo, la ínsula o nodos de la Red Frontoparietal) y el resto del cerebro correlaciona con el desempeño cognitivo.

- **Configuración en Resultados:**
    - En *Between-subjects effects*, seleccionas a tu grupo (ej. `AllSubjects`) y tu variable cognitiva (ej. `Memoria_Trabajo`).
    - En el contraste, configuras un modelo donde evalúas el efecto de la variable cognitiva: `[0 1]` (asumiendo que `AllSubjects` es el primer término y la covariable cognitiva es el segundo).
- **Interpretación:** Identificas regiones cuyos valores de conectividad aumentan o disminuyen proporcionalmente a mejores puntuaciones en la prueba cognitiva.

B. Teoría de Grafos y Eficiencia de Redes

La neurocognición compleja (como el razonamiento fluido o la flexibilidad cognitiva) suele depender de la eficiencia global y local de la red cerebral.

- **Métricas clave a correlacionar:**
    - **Eficiencia global (*Global Efficiency*):** Qué tan bien integrado está el cerebro para el procesamiento de información a larga distancia.
    - **Modularidad o Segregación:** Qué tan bien delimitados están los subsistemas funcionales (frecuentemente relacionada con la especialización eficiente).
    - **Centralidad de grado (*Degree Centrality*) de nodos clave:** Como los nodos de la Red Frontoparietal o la Red Saliente.
- **En CONN:** Puedes exportar las métricas de grafos calculadas por sujeto o analizarlas directamente en el módulo de segundo nivel seleccionando las medidas topológicas como variables dependientes.

3. Covariables de Confusión Esenciales (*Nuisance Covariates*)

Al correlacionar neuroimagen con cognición, es fundamental controlar variables sociodemográficas y técnicas para evitar falsos positivos:

- **Edad y Sexo:** Dado que la conectividad funcional y el rendimiento cognitivo varían con la edad y el sexo, deben incluirse siempre como covariables de no interés en el modelo de segundo nivel.

- **Movimiento (*Head Motion*):** Asegúrate de incluir el desplazamiento medio (*framewise displacement* o FD) como covariable a nivel de grupo, ya que el micromovimiento afecta sistemáticamente tanto a las métricas de conectividad en reposo como a las estimaciones cognitivas en ciertas poblaciones.
- **Nivel educativo / Años de escolaridad:** Altamente recomendable si la variable cognitiva es sensible al contexto sociocultural o académico.

4. Corrección por Comparaciones Múltiples

Al evaluar miles de vóxeles (*Seed-to-Voxel*) o cientos de conexiones (*ROI-to-ROI*), el riesgo de error Tipo I es elevado. En CONN debes aplicar umbrales rigurosos:

- **A nivel de vóxel/cluster:** Utiliza corrección por Campo Aleatorio Gaussiano (*Gaussian Random Field Theory* - GRF) con un umbral de cúmulo (*cluster-level FDR* o FWE $p < 0.05$), que es el estándar recomendado en la literatura actual de neuroimagen.
- **A nivel de ROI:** Corrección FDR (*False Discovery Rate*) para corregir por el número de conexiones evaluadas en la matriz.

¿Tienes pensado enfocar el análisis hacia alguna red cerebral específica (como la Red por Defecto o la Red Frontoparietal) o prefieres explorar todo el cerebro en busca de correlaciones guiadas por los datos?
