Modelo Matemático del ANOVA Unifactorial

https://gemini.google.com/app/eceb4465fe56b342

User prompt: Modelo de análisis de varianza

Response: El **Análisis de Varianza (ANOVA)** es un método estadístico paramétrico utilizado para comparar las medias de tres o más poblaciones evaluando la variabilidad total de los datos y descomponiéndola en componentes atribuidos a distintas fuentes de variación.

Modelo Matemático del ANOVA Unifactorial (One-Way)

Para un diseño de un solo factor con k niveles o tratamientos y n_i observaciones por grupo, la j-ésima observación del i-ésimo tratamiento se expresa mediante el modelo lineal:

$$Y_{ij} = \mu + \tau_i + \epsilon_{ij}$$

Donde:

- Y_{ij}: Valor de la variable respuesta para la observación j del grupo i.
- μ: Media general de la población.
- τ_i: Efecto diferencial del i-ésimo tratamiento o nivel ($\tau_i = \mu_i - \mu$).
- ϵ_{ij}: Término de error aleatorio o residual.

Supuestos Estadísticos del Modelo

1. **Normalidad:** Los residuos ϵ_{ij} siguen una distribución normal con media cero: $\epsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$.
2. **Homocedasticidad:** La varianza de los errores es constante entre todos los tratamientos: $\sigma_1^2 = \sigma_2^2 = \cdots = \sigma_k^2 = \sigma^2$.
3. **Independencia:** Las observaciones son estadísticamente independientes entre sí.

Contrastación de Hipótesis

El ANOVA determina si las diferencias entre las medias grupales son estadísticamente significativas o fruto del azar:

- **Hipótesis nula (H_0):** $\mu_1 = \mu_2 = \cdots = \mu_k$ (equivalente a $\tau_1 = \tau_2 = \cdots = \tau_k = 0$)
- **Hipótesis alternativa (H_1):** Al menos dos medias difieren entre sí (al menos un $\tau_i \neq 0$).

Descomposición de la Suma de Cuadrados

La variabilidad total del conjunto de datos se particiona conceptual y algebraicamente en dos componentes:

$$SS_{\text{Total}} = SS_{\text{Tratamiento}} + SS_{\text{Error}}$$

$$\sum_{i=1}^{k}\sum_{j=1}^{n_i}(Y_{ij} - \bar{Y}_{\cdot\cdot})^2 = \sum_{i=1}^{k} n_i(\bar{Y}_{i\cdot} - \bar{Y}_{\cdot\cdot})^2 + \sum_{i=1}^{k}\sum_{j=1}^{n_i}(Y_{ij} - \bar{Y}_{i\cdot})^2$$

Donde $\bar{Y}_{\cdot\cdot}$ es la media global y $\bar{Y}_{i\cdot}$ representa la media del i-ésimo grupo.

Tabla de Análisis de Varianza

Los componentes de variabilidad se organizan formalmente en la tabla ANOVA para calcular el estadístico de prueba F:

Fuente de Variación	Suma de Cuadrados (SS)	Grados de Libertad (df)	Cuadrados Medios (MS)	Estadístico F
Tratamiento (Entre grupos)	SS_{Trat}	$k - 1$	$MS_{\text{Trat}} = \frac{SS_{\text{Trat}}}{k-1}$	$F = \frac{MS_{\text{Trat}}}{MS_{\text{Error}}}$
Error (Dentro de grupos)	SS_{Error}	$N - k$	$MS_{\text{Error}} = \frac{SS_{\text{Error}}}{N-k}$	$-$
Total	SS_{Total}	$N - 1$	$-$	$-$

Donde $N = \sum_{i=1}^{k} n_i$. Bajo la hipótesis nula, el estadístico F sigue una distribución F de Snedecor con $(k-1, N-k)$ grados de libertad. Si el valor p asociado a F es menor al nivel de significancia α (e.g., 0.05), se rechaza H_0.

Variantes del Modelo

- **ANOVA Factorial (Two-Way / Bifactorial):** Analiza el impacto simultáneo de dos o más factores categóricos y su término de interacción ($\tau\beta_{ij}$).
- **ANOVA de Medidas Repetidas:** Se aplica cuando los mismos sujetos o unidades experimentales se evalúan en múltiples puntos temporales o condiciones.
- **ANCOVA (Análisis de Covarianza):** Modela la variable respuesta incluyendo factores categóricos y covariables continuas para reducir el error experimental.

User prompt: Muestra el código completo para ejecutar e interpretar un ANOVA de un factor con validación de supuestos y pruebas post-hoc en Python y R.

Response: 1. Implementación en Python

El flujo utiliza `statsmodels` para el modelo lineal y la tabla ANOVA, `scipy.stats` para la evaluación de supuestos y `statsmodels.stats.multicomp` para la prueba post-hoc de Tukey.

```
import numpy as np
import pandas as pd
import scipy.stats as stats
import statsmodels.api as sm
from statsmodels.formula.api import ols
from statsmodels.stats.multicomp import pairwise_tukeyhsd

# 1. Generación de datos sintéticos
np.random.seed(42)
grupo_A = np.random.normal(loc=12.0, scale=1.5, size=30)
grupo_B = np.random.normal(loc=14.5, scale=1.5, size=30)
grupo_C = np.random.normal(loc=11.8, scale=1.5, size=30)

df = pd.DataFrame({
    'valor': np.concatenate([grupo_A, grupo_B, grupo_C]),
    'grupo': ['A']*30 + ['B']*30 + ['C']*30
})
df['grupo'] = df['grupo'].astype('category')

# 2. Ajuste del modelo lineal (Ordinary Least Squares)
model = ols('valor ~ C(grupo)', data=df).fit()
residuos = model.resid

# 3. Validación de Supuestos
print("=== 1. VALIDACIÓN DE SUPUESTOS ===")

# a) Prueba de Normalidad de Residuos (Shapiro-Wilk)
stat_shapiro, p_shapiro = stats.shapiro(residuos)
print(f"Shapiro-Wilk (Residuos): W = {stat_shapiro:.4f}, p-valor = {p_shapiro:.4f}")
if p_shapiro > 0.05:
    print(" -> Se cumple el supuesto de normalidad (p > 0.05).")
else:
    print(" -> Violación del supuesto de normalidad (p <= 0.05). Considerar Kruskal-Wallis.")

# b) Prueba de Homocedasticidad (Levene)
stat_levene, p_levene = stats.levene(
    df[df['grupo']=='A']['valor'],
    df[df['grupo']=='B']['valor'],
    df[df['grupo']=='C']['valor']
)
print(f"Levene (Homocedasticidad): W = {stat_levene:.4f}, p-valor = {p_levene:.4f}")
if p_levene > 0.05:
    print(" -> Se cumple el supuesto de homocedasticidad (p > 0.05).")
else:
    print(" -> Violación de homocedasticidad. Usar ANOVA de Welch (pingouin.welch_anova).")

# 4. Tabla ANOVA
print("\n=== 2. TABLA ANOVA ===")
anova_table = sm.stats.anova_lm(model, typ=2)
```

```
print(anova_table)

# 5. Pruebas Post-Hoc (Tukey HSD)
p_anova = anova_table.loc['C(grupo)', 'PR(>F)']
if p_anova <= 0.05:
    print("\n=== 3. PRUEBA POST-HOC (Tukey HSD) ===")
    tukey = pairwise_tukeyhsd(endog=df['valor'], groups=df['grupo'], alpha=0.05)
    print(tukey)
else:
    print("\nEl efecto global no es significativo (p > 0.05). No se aplican pruebas post-hoc.")
```

2. Implementación en R

Utiliza las funciones base (`aov`, `shapiro.test`, `TukeyHSD`) y el paquete `car` para la prueba de Levene.

```
# Carga de paquetes
if (!require("car")) install.packages("car", dependencies = TRUE)
library(car)

# 1. Generación de datos sintéticos
set.seed(42)
grupo_A <- rnorm(30, mean = 12.0, sd = 1.5)
grupo_B <- rnorm(30, mean = 14.5, sd = 1.5)
grupo_C <- rnorm(30, mean = 11.8, sd = 1.5)

df <- data.frame(
  valor = c(grupo_A, grupo_B, grupo_C),
  grupo = factor(rep(c("A", "B", "C"), each = 30))
)

# 2. Ajuste del modelo ANOVA
fit <- aov(valor ~ grupo, data = df)
residuos <- residuals(fit)

# 3. Validación de Supuestos
cat("=== 1. VALIDACIÓN DE SUPUESTOS ===\n")

# a) Prueba de Normalidad de Residuos (Shapiro-Wilk)
shapiro_res <- shapiro.test(residuos)
cat(sprintf("Shapiro-Wilk (Residuos): W = %.4f, p-valor = %.4f\n",
            shapiro_res$statistic, shapiro_res$p.value))
if (shapiro_res$p.value > 0.05) {
  cat(" -> Se cumple el supuesto de normalidad (p > 0.05).\n")
} else {
  cat(" -> Violación del supuesto de normalidad. Considerar prueba de Kruskal-Wallis.\n")
}

# b) Prueba de Homocedasticidad (Levene)
levene_res <- leveneTest(valor ~ grupo, data = df)
p_levene <- levene_res$`Pr(>F)`[1]
cat(sprintf("Levene (Homocedasticidad): F = %.4f, p-valor = %.4f\n",
            levene_res$`F value`[1], p_levene))
if (p_levene > 0.05) {
  cat(" -> Se cumple el supuesto de homocedasticidad (p > 0.05).\n")
} else {
  cat(" -> Violación de homocedasticidad. Usar oneway.test(..., var.equal = FALSE).\n")
}

# 4. Tabla ANOVA
cat("\n=== 2. TABLA ANOVA ===\n")
anova_summary <- summary(fit)
print(anova_summary)

# 5. Pruebas Post-Hoc (Tukey HSD)
p_anova <- anova_summary[[1]][["Pr(>F)"]][1]
if (p_anova <= 0.05) {
  cat("\n=== 3. PRUEBA POST-HOC (Tukey HSD) ===\n")
  tukey_res <- TukeyHSD(fit)
  print(tukey_res)
} else {
  cat("\nEl efecto global no es significativo (p > 0.05). No se aplican pruebas post-hoc.\n")
}
```

3. Guía de Interpretación de Resultados

1. **Prueba de Shapiro-Wilk (Normalidad):**
   - H_0: Los residuos siguen una distribución normal.
   - Si $p > 0.05$, no se rechaza H_0; el supuesto de normalidad es válido.
   - *Alternativa no paramétrica ante fallo:* Prueba de Kruskal-Wallis.
2. **Prueba de Levene (Homocedasticidad):**
   - H_0: Las varianzas entre todos los grupos son iguales ($\sigma_1^2 = \sigma_2^2 = \cdots = \sigma_k^2$).
   - Si $p > 0.05$, las varianzas son homogéneas.
   - *Alternativa si $p \leq 0.05$:* ANOVA de Welch (`pingouin.welch_anova` en Python / `oneway.test(..., var.equal = FALSE)` en R).
3. **Tabla ANOVA (F-Test Global):**
   - Evalúa la columna $P(> F)$ o `PR(>F)`.
   - Si $p \leq 0.05$, existe evidencia estadísticamente significativa de que al menos una media grupal difiere de las demás.
4. **Prueba Post-Hoc de Tukey (HSD):**
   - Revisa el p-valor ajustado (`p-adj` o `p-adj` en el reporte) para cada par de grupos (e.g., B vs A, C vs A, C vs B).
   - Si el intervalo de confianza de la diferencia no incluye el cero ($p_{\text{adj}} \leq 0.05$), ese par específico presenta una diferencia estadísticamente significativa.

User prompt: Muestra la implementación para ejecutar un ANOVA de dos factores (Bifactorial) con interacción, validación de supuestos y gráficos de interacción en Python y R.

Response: 1. Implementación en Python

Se utiliza `statsmodels` para el modelo lineal y la generación de la tabla ANOVA Tipo II/III, `scipy.stats` para las validaciones de supuestos y `matplotlib` / `statsmodels` para los gráficos de interacción.

```
import numpy as np
import pandas as pd
import scipy.stats as stats
import statsmodels.api as sm
from statsmodels.formula.api import ols
from statsmodels.graphics.factorplots import interaction_plot
from statsmodels.stats.multicomp import pairwise_tukeyhsd
import matplotlib.pyplot as plt

# 1. Generación de datos sintéticos con interacción real
np.random.seed(42)
n_per_cell = 20

dieta = np.repeat(['Control', 'Tratamiento'], n_per_cell * 3)
dosis = np.tile(np.repeat(['Baja', 'Media', 'Alta'], n_per_cell), 2)

# Definición de efectos principales y término de interacción
base = 10.0
efecto_dieta = np.where(dieta == 'Tratamiento', 2.0, 0.0)
efecto_dosis = np.where(dosis == 'Media', 1.5, np.where(dosis == 'Alta', 4.0, 0.0))
# Efecto sinérgico de interacción (solo Tratamiento + Alta Dosis)
interaccion = np.where((dieta == 'Tratamiento') & (dosis == 'Alta'), 3.5, 0.0)

ruido = np.random.normal(0, 1.2, size=len(dieta))
valor = base + efecto_dieta + efecto_dosis + interaccion + ruido

df = pd.DataFrame({'dieta': dieta, 'dosis': dosis, 'valor': valor})
df['dieta'] = df['dieta'].astype('category')
df['dosis'] = pd.Categorical(df['dosis'], categories=['Baja', 'Media', 'Alta'], ordered=True)

# 2. Ajuste del Modelo Lineal con Término de Interacción
```

```
# El operador '*' en la fórmula incluye ambos efectos principales y su interacción
model = ols('valor ~ C(dieta) * C(dosis)', data=df).fit()
residuos = model.resid

# 3. Validación de Supuestos
print("=== 1. VALIDACIÓN DE SUPUESTOS ===")

# a) Normalidad de los Residuos
stat_shapiro, p_shapiro = stats.shapiro(residuos)
print(f"Shapiro-Wilk (Residuos): W = {stat_shapiro:.4f}, p-valor = {p_shapiro:.4f}")

# b) Homocedasticidad entre la combinación de tratamientos (Levene)
celdas = [grupo['valor'].values for _, grupo in df.groupby(['dieta', 'dosis'], observed=True)]
stat_levene, p_levene = stats.levene(*celdas)
print(f"Levene (Homocedasticidad combinada): W = {stat_levene:.4f}, p-valor = {p_levene:.4f}")

# 4. Tabla ANOVA Bifactorial (Tipo II para diseños balanceados)
print("\n=== 2. TABLA ANOVA BIFACTORIAL ===")
anova_table = sm.stats.anova_lm(model, typ=2)
print(anova_table)

# 5. Pruebas Post-Hoc si existe interacción o efectos principales significativos
df['interaccion_grupo'] = df['dieta'].astype(str) + "_" + df['dosis'].astype(str)
tukey = pairwise_tukeyhsd(endog=df['valor'], groups=df['interaccion_grupo'], alpha=0.05)
print("\n=== 3. PRUEBA POST-HOC DE TUKEY (Combinación de Celdas) ===")
print(tukey)

# 6. Gráfico de Interacción
fig, ax = plt.subplots(figsize=(8, 5))
interaction_plot(
    x=df['dosis'],
    trace=df['dieta'],
    response=df['valor'],
    colors=['#1f77b4', '#ff7f0e'],
    markers=['o', 's'],
    ms=7,
    ax=ax
)
ax.set_title("Gráfico de Interacción: Dieta x Dosis")
ax.set_ylabel("Media del Valor Respuesta")
ax.set_xlabel("Nivel de Dosis")
plt.grid(True, linestyle='--', alpha=0.5)
plt.tight_layout()
plt.show()
```

2. Implementación en R

Utiliza `car` para la tabla ANOVA con sumas de cuadrados Tipo II y `ggplot2` para la visualización del perfil de medias e interacción.

```
# Carga de librerías necesarias
if (!require("car")) install.packages("car", dependencies = TRUE)
if (!require("ggplot2")) install.packages("ggplot2", dependencies = TRUE)
library(car)
library(ggplot2)

# 1. Generación de datos sintéticos
set.seed(42)
n_cell <- 20

df <- expand.grid(
  dosis = factor(c("Baja", "Media", "Alta"), levels = c("Baja", "Media", "Alta")),
  dieta = factor(c("Control", "Tratamiento")),
  rep = 1:n_cell
)

# Definición de efectos principales e interacción sinérgica
efecto_dieta <- ifelse(df$dieta == "Tratamiento", 2.0, 0.0)
efecto_dosis <- ifelse(df$dosis == "Media", 1.5, ifelse(df$dosis == "Alta", 4.0, 0.0))
interaccion <- ifelse(df$dieta == "Tratamiento" & df$dosis == "Alta", 3.5, 0.0)

df$valor <- 10.0 + efecto_dieta + efecto_dosis + interaccion + rnorm(nrow(df), mean = 0, sd = 1.2)

# 2. Ajuste del Modelo ANOVA Bifactorial
fit <- aov(valor ~ dieta * dosis, data = df)
```

```
residuos <- residuals(fit)

# 3. Validación de Supuestos
cat("=== 1. VALIDACIÓN DE SUPUESTOS ===\n")

# a) Normalidad de los Residuos
shapiro_res <- shapiro.test(residuos)
cat(sprintf("Shapiro-Wilk (Residuos): W = %.4f, p-valor = %.4f\n",
            shapiro_res$statistic, shapiro_res$p.value))

# b) Homocedasticidad (Prueba de Levene en la interacción de factores)
levene_res <- leveneTest(valor ~ dieta * dosis, data = df)
cat(sprintf("Levene (Homocedasticidad): F = %.4f, p-valor = %.4f\n",
            levene_res$`F value`[1], levene_res$`Pr(>F)`[1]))

# 4. Tabla ANOVA
cat("\n=== 2. TABLA ANOVA BIFACTORIAL ===\n")
# Uso de Anova() de paquete car para tipo II
anova_type2 <- Anova(lm(valor ~ dieta * dosis, data = df), type = "II")
print(anova_type2)

# 5. Pruebas Post-Hoc de Tukey
cat("\n=== 3. PRUEBA POST-HOC (Tukey HSD) ===\n")
print(TukeyHSD(fit))

# 6. Gráfico de Interacción con ggplot2
df_means <- aggregate(valor ~ dieta + dosis, data = df, FUN = mean)

ggplot(df_means, aes(x = dosis, y = valor, color = dieta, group = dieta)) +
  geom_line(linewidth = 1) +
  geom_point(size = 3) +
  labs(
    title = "Gráfico de Interacción: Dieta x Dosis",
    x = "Nivel de Dosis",
    y = "Media de Valor Respuesta",
    color = "Dieta"
  ) +
  theme_minimal() +
  theme(plot.title = element_text(hjust = 0.5, face = "bold"))
```

3. Claves de Interpretación del ANOVA Bifactorial

1. **Jerarquía en la Interpretación:**
    - **Evaluar primero la Interacción ($A \times B$):** Si el término de interacción es significativo ($p \leq 0.05$), el efecto de un factor depende del nivel del otro factor. En este escenario, la interpretación de los efectos principales por separado pierde validez y se deben analizar los **efectos simples** (comparaciones dentro de cada celda).
    - **Efectos Principales (A y B):** Si la interacción **no** es significativa ($p > 0.05$), se procede a interpretar directamente las filas individuales de cada factor principal.
2. **Lectura del Gráfico de Interacción:**
    - **Líneas paralelas:** Indican ausencia de interacción. El efecto de cambio entre niveles es constante sin importar la categoría del segundo factor.
    - **Líneas no paralelas o que se cruzan:** Indican presencia de interacción ordinal o no ordinal. Las diferencias en el cambio de respuesta justifican las pruebas post-hoc globales por combinación de celdas.

User prompt: Muestra cómo ajustar un ANOVA de dos factores para datos desbalanceados con Sumas de Cuadrados Tipo III y cómo contrastar frente a un Modelo Lineal Mixto.

Response: En un diseño experimental desbalanceado (número desigual de observaciones por celda), las sumas de cuadrados estándar (Tipo I) dependen del orden de entrada de los factores en la fórmula debido a la pérdida de ortogonalidad.

Para solucionar esto se recurre a la **Suma de Cuadrados Tipo III**, la cual evalúa el efecto marginal de cada factor en presencia de todos los demás términos (incluida la interacción). Sin embargo, la prueba Tipo III requiere **codificación de contrastes ortogonales (contraste suma o *sum-to-zero*)** para ser estadísticamente válida.

Por su parte, los **Modelos Lineales Mixtos (LMM)** extienden esta estimación mediante **REML** (Restricted Maximum Likelihood), permitiendo modelar estructuras complejas como bloques aleatorios, medidas repetidas o datos desbalanceados sin distorsionar la estimación de varianza.

1. Implementación en Python

Se utiliza `statsmodels` especificando contrastes de suma (`C(factor, Sum)`) para el ANOVA Tipo III, y la API de `mixedlm` para el Modelo Lineal Mixto con un efecto aleatorio por bloque/sujeto.

```
import numpy as np
import pandas as pd
import statsmodels.api as sm
from statsmodels.formula.api import ols, mixedlm
from statsmodels.stats.anova import anova_lm

# 1. Generación de datos sintéticos desbalanceados
np.random.seed(42)

# Tamaños muestrales desbalanceados por celda
tamaños = {
    ('Control', 'Baja'): 15, ('Control', 'Media'): 22, ('Control', 'Alta'): 18,
    ('Tratamiento', 'Baja'): 10, ('Tratamiento', 'Media'): 25, ('Tratamiento', 'Alta'): 12
}

registros = []
sujeto_id = 1

for (dieta, dosis), n in tamaños.items():
    # Efectos reales
    ef_dieta = 2.0 if dieta == 'Tratamiento' else 0.0
    ef_dosis = 1.5 if dosis == 'Media' else (4.0 if dosis == 'Alta' else 0.0)
    ef_int = 3.0 if (dieta == 'Tratamiento' and dosis == 'Alta') else 0.0

    # Asignación de bloques aleatorios (e.g., 5 lotes/hospitales)
    bloques = np.random.choice([f'Bloque_{i}' for i in range(1, 6)], size=n)
    ef_bloques = {'Bloque_1': -1.2, 'Bloque_2': -0.5, 'Bloque_3': 0.2, 'Bloque_4': 0.8, 'Bloque_5': 1.1}

    for b in bloques:
        ruido = np.random.normal(0, 1.2)
        y = 10.0 + ef_dieta + ef_dosis + ef_int + ef_bloques[b] + ruido
        registros.append({'dieta': dieta, 'dosis': dosis, 'bloque': b, 'valor': y})

df = pd.DataFrame(registros)

# ==============================================================================
# A. ANOVA TIPO III (Modelo Lineal General con OLS)
# ==============================================================================
# IMPORTANTE: Para Tipo III es OBLIGATORIO configurar contrastes de suma (Sum)
modelo_ols = ols('valor ~ C(dieta, Sum) * C(dosis, Sum)', data=df).fit()

print("=== 1. TABLA ANOVA TIPO III (DATOS DESBALANCEADOS) ===")
anova_tipo3 = anova_lm(modelo_ols, typ=3)
print(anova_tipo3)


# ==============================================================================
# B. MODELO LINEAL MIXTO (LMM)
# ==============================================================================
# Modela los factores fijos (dieta, dosis e interacción) y el bloque como efecto aleatorio (intersección aleat
modelo_lmm = mixedlm(
    formula="valor ~ C(dieta) * C(dosis)",
    data=df,
    groups=df["bloque"]
).fit()

print("\n=== 2. RESUMEN DEL MODELO LINEAL MIXTO (LMM) ===")
print(modelo_lmm.summary())
```

2. Implementación en R

En R, la función base `anova()` calcula Tipo I. Para obtener Tipo III se utiliza la función `Anova()` del paquete `car` configurando previamente `options(contrasts = ...)`. Para LMM se emplean `lme4` y `lmerTest`.

```
# Carga de librerías necesarias
if (!require("car")) install.packages("car", dependencies = TRUE)
if (!require("lme4")) install.packages("lme4", dependencies = TRUE)
if (!require("lmerTest")) install.packages("lmerTest", dependencies = TRUE)
```

```
library(car)
library(lme4)
library(lmerTest)

# 1. Generación de datos sintéticos desbalanceados
set.seed(42)

dieta_niveles <- c("Control", "Tratamiento")
dosis_niveles <- c("Baja", "Media", "Alta")
bloques_niveles <- paste0("Bloque_", 1:5)

# Creación de muestras desbalanceadas
df_list <- list()
tamaños <- c(15, 22, 18, 10, 25, 12)
idx <- 1

for (d in dieta_niveles) {
  for (dos in dosis_niveles) {
    n <- tamaños[idx]
    bloques <- sample(bloques_niveles, size = n, replace = TRUE)

    ef_dieta <- ifelse(d == "Tratamiento", 2.0, 0.0)
    ef_dosis <- ifelse(dos == "Media", 1.5, ifelse(dos == "Alta", 4.0, 0.0))
    ef_int <- ifelse(d == "Tratamiento" & dos == "Alta", 3.0, 0.0)

    ef_bloque <- c("Bloque_1" = -1.2, "Bloque_2" = -0.5, "Bloque_3" = 0.2,
                   "Bloque_4" = 0.8, "Bloque_5" = 1.1)[bloques]

    valor <- 10.0 + ef_dieta + ef_dosis + ef_int + ef_bloque + rnorm(n, mean = 0, sd = 1.2)

    df_list[[idx]] <- data.frame(dieta = d, dosis = dos, bloque = bloques, valor = valor)
    idx <- idx + 1
  }
}

df <- do.call(rbind, df_list)
df$dieta <- factor(df$dieta)
df$dosis <- factor(df$dosis, levels = c("Baja", "Media", "Alta"))
df$bloque <- factor(df$bloque)

# ==============================================================================
# A. ANOVA TIPO III (OBLIGATORIO configurar contr.sum)
# ==============================================================================
# Ajuste global de contrastes a tipo suma
options(contrasts = c("contr.sum", "contr.poly"))

modelo_lm <- lm(valor ~ dieta * dosis, data = df)

cat("=== 1. TABLA ANOVA TIPO III (car::Anova) ===\n")
anova_tipo3 <- Anova(modelo_lm, type = "III")
print(anova_tipo3)

# Restaurar contrastes por defecto (contr.treatment)
options(contrasts = c("contr.treatment", "contr.poly"))


# ==============================================================================
# B. MODELO LINEAL MIXTO (lme4 / lmerTest)
# ==============================================================================
# Factor fijo: dieta * dosis | Factor aleatorio: (1 | bloque)
modelo_lmm <- lmer(valor ~ dieta * dosis + (1 | bloque), data = df)

cat("\n=== 2. TABLA ANOVA PARA EL MODELO MIXTO (Tipo III mediante REML) ===\n")
# lmerTest proporciona la tabla ANOVA con aproximación de Satterthwaite para df
print(anova(modelo_lmm, type = 3))

cat("\n=== 3. RESUMEN DE COMPONENTES DE VARIANZA (LMM) ===\n")
print(summary(modelo_lmm))
```

3. Cuadro Comparativo: ANOVA Tipo III vs. Modelo Lineal Mixto

Criterio	ANOVA Tipo III (OLS)	Modelo Lineal Mixto (LMM / REML)
Manejo de Desbalance	Ajusta sumas de cuadrados ajustando cada efecto marginalmente. Sensible a celdas totalmente vacías.	Modela de forma natural frecuencias desiguales sin requerir ortogonalidad en el diseño.
Naturaleza de Factores	Todos los factores se tratan como **efectos fijos**.	Permite combinar **efectos fijos** (tratamientos) y **aleatorios** (bloques, sujetos, centros).
Estructura de Varianza	Asume varianza homogénea e independencia entre observaciones.	Permite estimar componentes de varianza inter-bloque (σ_b^2) e intra-bloque (σ_e^2).
Requisito Técnico	**Obligatorio** definir contrastes de suma (`contr.sum` / `Sum`). De lo contrario, los valores p calculados son matemáticamente incorrectos.	No depende estrictamente de los contrastes para estimar los componentes de varianza y los efectos fijos.
Atribución de Error	La variabilidad debida a bloques no controlados se va directamente al término de error residual (SS_{Error}).	Aísla la variabilidad del grupo o bloque, reduciendo el error residual y aumentando la potencia estadística sobre los efectos fijos.
