Obtención de la Red por Defecto en rs-fMRI

https://gemini.google.com/app/c28f7cfe28b00dfe

User prompt: Cómo puedo obtener la Red por Defecto en imágenes de resonancia magnética funcional en estado en reposo

Response: Para obtener la **Red por Defecto (Default Mode Network - DMN)** en imágenes de resonancia magnética funcional en estado en reposo (rs-fMRI), existen principalmente **tres metodologías estándar**, dependiendo de si buscas un enfoque guiado por hipótesis (semillas) o un enfoque exploratorio/basado en datos (ICA o atlas).

A continuación, se detallan los enfoques más utilizados en la investigación actual y cómo implementarlos:

1. Análisis de Conectividad Basado en Semilla (Seed-Based Connectivity)

Este enfoque parte de una hipótesis anatómica y funcional. Se selecciona una región de interés (ROI) clave dentro de la DMN, se extrae su serie de tiempo y se calcula la correlación voxel a voxel con el resto del cerebro.

- **Región semilla clásica:** La **Corteza Cingulada Posterior (PCC)** o el Precuneus.
  - *Coordenadas MNI de referencia aproximadas:* $x = 0$, $y = -53$, $z = 26$ (o $z = 40$ según la literatura).
- **Pasos metodológicos:**
  1. **Preprocesamiento:** Corrección de movimiento, realineamiento, co-registro anatómico-funcional, normalización espacial (espacio MNI) y filtrado pasa-altas/bajas (ej. $0.01 - 0.1$ Hz).
  2. **Regresión de nuisances (ruido):** Control de señales espurias (matriz de diseño con parámetros de movimiento de 6 o 24 reductores, señal de sustancia blanca y líquido cefalorraquídeo, y opcionalmente *Global Signal Regression*).
  3. **Extracción y Correlación:** Se extrae la serie de tiempo promedio de los voxeles dentro de la esfera de la PCC y se calcula el coeficiente de correlación de Pearson con cada voxel del cerebro.
  4. **Transformación Fisher-z:** Se convierte el mapa de correlación r a una puntuación z para normalizar la distribución antes de las estadísticas de segundo nivel.

2. Análisis de Componentes Independientes (ICA - Independent Component Analysis)

Es una técnica de datos masivos no supervisada que descompone la matriz 4D de fMRI en componentes espaciales estadísticamente independientes y sus respectivas series de tiempo temporales.

- **Herramientas comunes:** MELODIC (en FSL), GIFT, o `CanICA` en **Nilearn** (Python).
- **Pasos metodológicos:**
  1. Se aplica ICA a nivel de grupo o individual (típicamente descomponiendo en 20 a 70 componentes).
  2. **Identificación de la red:** Se inspeccionan los mapas espaciales resultantes para identificar visualmente aquellos que coinciden con la topografía de la DMN (caracterizada por la activación sincrónica en PCC, precuneus, corteza prefrontal medial, y lóbulos parietales inferiores).
  3. También se puede automatizar la identificación calculando la **correlación espacial** o el coeficiente de Dice entre los componentes independientes obtenidos y una plantilla de referencia estándar (como las redes de Yeo o Smith).

3. Enfoque por Atlas o Parcelación Funcional (Atlas-Based / ROI)

Si prefieres no calcular matrices voxel a voxel, puedes utilizar parcelaciones cerebrales predefinidas que ya

segmentan la DMN en nodos específicos.

- **Plantillas recomendadas:**
  - **Yeo 7 Networks o 17 Networks** (la DMN suele corresponder a las redes 7 y 8 en la versión de 17 redes, o la red 7 en la de 7 redes).
  - **Schaefer Parcellation** (con resoluciones de 100, 200 o 400 parcelas, donde las etiquetas incluyen sub-redes de la DMN).
- **Procedimiento:** Se extraen las series de tiempo promedio de cada parcela perteneciente a la DMN y se construye una matriz de conectividad funcional (matriz de correlación de Pearson de $N \times N$), o se evalúa la conectividad intra-red promediando las correlaciones entre todos los nodos de la DMN.

Implementación rápida en Python (Nilearn)

Si trabajas con Python y cuentas con datos preprocesados (por ejemplo, con fMRIPrep), puedes extraer componentes de tipo DMN rápidamente utilizando ICA con `Nilearn`:

```
from nilearn.decomposition import CanICA
from nilearn.plotting import plot_stat_map

# Cargar tus imágenes 4D de rs-fMRI preprocesadas
func_filenames = ['sub-01_task-rest_bold.nii.gz', 'sub-02_task-rest_bold.nii.gz']

# Configurar CanICA para extraer, por ejemplo, 20 componentes
canica = CanICA(n_components=20, smoothing_fwhm=6.0,
                memory='nilearn_cache', memory_level=1,
                random_state=0)

# Ajustar el modelo
canica.fit(func_filenames)

# Obtener los mapas espaciales de los componentes
components_img = canica.components_img_

# Visualizar el componente que corresponda a la Red por Defecto (ej. índice visualizado)
plot_stat_map(components_img, title='Componentes ICA', display_mode='z', cut_coords=3)
```

¿Prefieres realizar este análisis utilizando un entorno gráfico y de caja blanca como **CONN Toolbox** en MATLAB, o estás implementando un pipeline automatizado en **Python** (usando Nilearn / AFNI / FSL)?

User prompt: Conn toolbox

Response: Para aislar y analizar la **Red por Defecto (DMN)** en **CONN Toolbox** (entorno basado en MATLAB y SPM), el proceso es sumamente intuitivo ya que la plataforma incluye plantillas integradas (*networks atlas*) y pipelines preconfigurados para este fin.

A continuación te presento la guía paso a paso para ejecutar el análisis, desde la importación hasta la visualización de la DMN.

Paso 1: Configuración del Proyecto y Datos (`Setup`)

1. Abre CONN desde MATLAB escribiendo `conn` en la consola.
2. En la pestaña **Setup**:
   - **Basic:** Define el TR (Repetition Time) de tus secuencias y el número de sujetos y sesiones.
   - **Structural / Functional:** Carga las imágenes anatómicas (`T1w.nii`) y funcionales (`bold.nii`). *Nota: Si*

utilizaste fMRIPrep, puedes importar directamente el dataset mediante "Import from BIDS / fMRIPrep".

- **ROIs:** CONN carga automáticamente el atlas de redes `networks.nii` (basado en el atlas de Yeo), el cual incluye por defecto las ROIs de la DMN:
  - `DMN.PCC` (Posterior Cingulate Cortex / Precuneus)
  - `DMN.MPFC` (Medial Prefrontal Cortex)
  - `DMN.LP (L)` y `DMN.LP (R)` (Lateral Parietal / Temporal-Parietal Junction)

Paso 2: Preprocesamiento Funcional (`Preprocessing`)

Si tus datos están crudos, ejecuta el pipeline por defecto (*Default Preprocessing Pipeline for Volume-based analyses*):

1. Ve al botón **Functional -> Preprocessing**.
2. Asegúrate de incluir los pasos de **Realignment**, **Direct Segmentation & Normalization (MNI space)**, y **Smoothing** (un kernel Gaussiano de $6\ \text{mm}$ o $8\ \text{mm}$ FWHM es el estándar adecuado para la DMN).

Paso 3: Limpieza de Ruido (`Denoising`)

El denoising es crítico en *resting-state* para eliminar artefactos por movimiento y fisiológicos sin alterar las fluctuaciones de baja frecuencia:

1. En la pestaña **Denoising**, verifica la regresión de confusores (método CompCor):
   - Parámetros de movimiento (6 de movimiento + sus derivadas).
   - Señal de Sustancia Blanca (*White Matter*) y Líquido Cefalorraquídeo (*CSF*).
2. **Filtrado temporal:** Aplica el filtro pasa-banda por defecto para resting-state:
$$0.01\ \text{Hz} \leq f \leq 0.1\ \text{Hz}$$
3. Haz clic en **Done** para procesar la serie temporal de todos los sujetos.

Paso 4: Análisis de Primer Nivel (`First-level Analyses`)

CONN te permite extraer la DMN mediante dos enfoques principales dentro de la pestaña *First-level*:

Opción A: Seed-to-Voxel (Basado en Semilla)

1. Selecciona como semilla (**Seed/Source**) la ROI `DMN.PCC` o `DMN.MPFC`.
2. CONN calculará la correlación temporal entre esta semilla y cada voxel del cerebro, generando el mapa clásico de la Red por Defecto.

Opción B: ROI-to-ROI (Matriz de Conectividad)

1. Selecciona el conjunto de semillas etiquetado como `networks.DMN`.
2. Podrás evaluar la fuerza de la conectividad intrínseca (r de Pearson transformada a z) entre los 4 nodos principales de la DMN (PCC, MPFC, LP_L, LP_R).

Paso 5: Resultados de Segundo Nivel y Visualización (`Second-level Results`)

1. Ve a la pestaña **Second-level Results**.
2. Elige la pestaña **Seed-to-Voxel** o **ROI-to-ROI**.

3. Selecciona la prueba estadística deseada (por ejemplo, *One-sample t-test* para ver el patrón general de la DMN en tu grupo).
4. **Visualización en 3D:**
    - Haz clic en **Results Explorer**.
    - Define el umbral voxel ($p < 0.001$ no corregido) y el umbral de clúster ($p < 0.05$ corregido por FDR o FWE).
    - Selecciona **3D Display** para proyectar la DMN sobre una superficie cortical inflada (similar a FreeSurfer), donde verás claramente los focos hiperconectados en PCC, MPFC y bilat-LP.

¿Tus datos ya fueron preprocesados externamente (por ejemplo con fMRIPrep o SPM) y solo planeas hacer el Denoising en CONN, o vas a realizar todo el preprocesamiento desde la interfaz gráfica?

User prompt: Realizar todo el preprocesamiento

Response: Para realizar **todo el preprocesamiento directamente en CONN Toolbox** desde las imágenes nativas (anatómicas y funcionales sin procesar), la herramienta cuenta con un pipeline automatizado estándar (`Default preprocessing pipeline`) que deja los datos listos para el análisis de conectividad en estado en reposo.

A continuación, tienes el procedimiento paso a paso para configurar y ejecutar este flujo de trabajo en la interfaz gráfica de CONN:

Paso 1: Configuración Inicial del Proyecto (`Setup: Basic`)

1. Abre MATLAB y escribe `conn` en la ventana de comandos para lanzar la interfaz gráfica.
2. Haz clic en **New** para crear un nuevo proyecto.
3. En la pestaña **Basic**:
    - **Number of subjects:** Indica el número de sujetos que vas a procesar.
    - **TR (Repetition Time):** Introduce el TR exacto de tu secuencia funcional en segundos (por ejemplo, 2 o `1.5`, según tus parámetros de adquisición).
    - **Number of sessions:** Especifica cuántas sesiones de *resting-state* tiene cada sujeto (generalmente 1).

Paso 2: Importación de Datos Anatómicos y Funcionales (`Setup: Structural & Functional`)

1. Ve a la pestaña **Setup -> Structural**:
    - Selecciona los archivos de imagen anatómica en formato NIfTI (`.nii` o `.nii.gz`) para cada sujeto (típicamente las imágenes ponderadas en T1).
2. Ve a la pestaña **Setup -> Functional**:
    - Selecciona las series temporales funcionales en estado en reposo de cada sujeto. Asegúrate de que el orden de los sujetos coincida exactamente con la pestaña estructural.

Paso 3: Ejecución del Pipeline Completo de Preprocesamiento

CONN automatiza todo el proceso de alineación, normalización y suavizado mediante una sola interfaz.

1. En la pestaña **Setup**, haz clic en el botón inferior izquierdo **Preprocessing** (o dirígete al menú superior correspondiente). Se abrirá una ventana de configuración de lotes.

2. En el menú desplegable de pipelines, selecciona la opción estándar:
    - **Default preprocessing pipeline for volume-based analyses (milestone / standard)**.
3. Verifica o ajusta los pasos incluidos en este pipeline por defecto (se ejecutan en secuencia lógica):
    - **Functional realignment & unwarping:** Corrección de movimiento entre volúmenes y distorsiones de susceptibilidad magnética.
    - **Functional slice-timing correction:** Corrección de retardos en la adquisición de cortes (si aplica; puedes omitirlo si usaste adquisiciones multibanda con TR corto).
    - **Functional outlier detection (ART-based scrubbing):** Identificación automática de volúmenes con movimiento excesivo o picos de señal global para su posterior control.
    - **Structural normalization & segmentation:** Segmentación del espacio anatómico en Materia Gris, Materia Blanca y Líquido Cefalorraquídeo (LCR), y normalización al espacio estándar MNI.
    - **Functional normalization:** Normalización espacial de las imágenes funcionales al espacio MNI utilizando los parámetros obtenidos del T1.
    - **Functional smoothing:** Aplicación de un suavizado espacial con un filtro Gaussiano (por defecto viene configurado a $8\ \mathrm{mm}$ FWHM, aunque para análisis de DMN fina algunos investigadores prefieren $6\ \mathrm{mm}$).
4. Haz clic en **Start**. CONN comenzará a procesar a todos los sujetos de manera secuencial (este proceso puede tardar varios minutos por sujeto dependiendo de la capacidad de cómputo).

Paso 4: Verificación de Calidad y Asignación de ROIs (`Setup: ROIs`)

Una vez finalizado el preprocesamiento:

1. Revisa la pestaña **Setup -> ROIs**:
    - Asegúrate de que las plantillas estándar estén cargadas. Para aislar la Red por Defecto, verifica que estén disponibles las ROIs del paquete `networks` (específicamente `networks.DMN` o los nodos individuales como `PCC`, `MPFC`, `LP`).
2. Utiliza las herramientas de visualización de CONN (el botón de control de calidad o *Quality Assurance*) para revisar las imágenes anatómicas normalizadas y asegurarte de que la segmentación del cerebro y la superposición con el espacio MNI sean correctas.

Una vez completados estos pasos, tus datos estarán listos para pasar a la pestaña **Denoising** (limpieza de ruido con CompCor y filtrado pasa-banda) y posteriormente extraer la DMN en **First-level Analyses**. ¿Tus datos cuentan con archivos de tiempos de eco o parámetros adicionales de movimiento, o prefieres mantener los ajustes estándar del pipeline de CONN?
