Temario Curso Posgrado Machine Learning

https://gemini.google.com/app/652673b95cb82b35

User prompt: Dame un temario para impartir un curso de machine learning a nivel posgrado

Response: Este temario está diseñado para un curso semestral (16 semanas) a nivel maestría o doctorado. Asume que los estudiantes cuentan con bases sólidas en álgebra lineal, cálculo multivariable, probabilidad, estadística y programación en Python.

Módulo 1: Fundamentos y Teoría del Aprendizaje (Semanas 1-3)

- **Semana 1: Introducción y Formulación del Aprendizaje Estadístico**
  - Espacios de hipótesis, función de pérdida y riesgo empírico.
  - Trade-off Varianza-Sesgo (*Bias-Variance Tradeoff*).
  - Validación cruzada y métodos de remuestreo (*Bootstrap*).
- **Semana 2: Teoría del Aprendizaje Estadístico**
  - Desigualdades de concentración (Hoeffding, McDiarmid).
  - Dimensión Vapnik-Chervonenkis (VC) y Complejidad de Rademacher.
  - Límites de generalización (*Generalization Bounds*) y PAC Learning.
- **Semana 3: Optimización Convexa para Machine Learning**
  - Descenso de Gradiente (GD, SGD, Adam).
  - Condiciones de Karush-Kuhn-Tucker (KKT) y dualidad de Lagrange.
  - Métodos de segundo orden (Newton, L-BFGS).

Módulo 2: Modelos Discriminativos y Generativos Clásicos (Semanas 4-7)

- **Semana 4: Modelos Lineales Formales y Regularización**
  - Regresión Lineal/Logística desde una perspectiva probabilística.
  - Regularización L1 (Lasso, subgradientes, Sparsity) y L2 (Ridge).
  - *Elastic Net* y métodos de selección de características.
- **Semana 5: Métodos de Núcleo (*Kernel Methods*)**
  - Teorema de Representación de Riesz y Espacios de Hilbert con Núcleo Reproducible (RKHS).
  - Máquinas de Vectores de Soporte (SVM) para clasificación y regresión.
  - PCA Kernel y Regresión Ridge con Kernel.

- **Semana 6: Modelos Basados en Árboles y *Ensemble Learning***
    - Árboles de decisión (Criterios de información: Entropía, Gini).
    - *Bagging* y Random Forests (análisis de convergencia).
    - *Boosting*: AdaBoost, Gradient Boosting Machines (GBM), XGBoost y LightGBM.
- **Semana 7: Aprendizaje Bayesiano y Modelos Generativos**
    - Estimación de Máxima Verosimilitud (MLE) vs. Máximo a Posteriori (MAP).
    - Regresión y Clasificación Bayesiana.
    - Naive Bayes, Análisis de Discriminante Lineal/Cuadrático (LDA/QDA).

Módulo 3: Aprendizaje No Supervisado y Probabilístico (Semanas 8-10)

- **Semana 8: Reducción de Dimensionalidad y Aprendizaje de Manifolds**
    - PCA, SVD y Análisis Factorial.
    - Reducción no lineal: t-SNE, UMAP, Isomap y LLE.
- **Semana 9: Agrupamiento (*Clustering*) y Densidad**
    - K-Means, K-Medoides y convergencia.
    - Agrupamiento Jerárquico y DBSCAN.
    - Estimación de Densidad por Núcleo (KDE).
- **Semana 10: Modelos Gráficos Probabilísticos y Algoritmo EM**
    - Modelos de Mezclas Gaussianas (GMM).
    - Algoritmo de Maximización de la Esperanza (EM) y sus garantías teóricas.
    - Redes Bayesianas y Campos Aleatorios de Markov (MRF).

Módulo 4: Redes Neuronales y Aprendizaje Profundo (Semanas 11-13)

- **Semana 11: Fundamentos de Deep Learning**
    - Perceptrón Multicapa (MLP) y Teorema de Aproximación Universal.
    - Algoritmo de Propagación Hacia Atrás (*Backpropagation*) y diferenciación automática.
    - Fenómenos de desvanecimiento/explosión de gradiente y técnicas de estabilización (BatchNorm, LayerNorm, Residual Connections).
- **Semana 12: Arquitecturas Especializadas**
    - Redes Neuronales Convolucionales (CNNs) y operaciones de convolución.

    - Redes Recurrentes (RNN, LSTM, GRU) y procesamiento de secuencias.
    - Mecanismos de Atención y Arquitectura *Transformer*.
- **Semana 13: Modelos Generativos Profundos**
    - Autoencoders y Autoencoders Variacionales (VAEs).
    - Redes Generativas Adversarias (GANs).
    - Introducción a Modelos de Difusión.

Módulo 5: Temas Avanzados y Evaluación (Semanas 14-16)

- **Semana 14: Aprendizaje por Refuerzo (*Reinforcement Learning*)**
    - Procesos de Decisión de Markov (MDP).
    - Ecuaciones de Bellman y Programación Dinámica.
    - Q-Learning, SARSA y métodos de Gradiente de Política (*Policy Gradient*).
- **Semana 15: Temas Contemporáneos e Sostenibilidad**
    - Aprendizaje Autosupervisado (*Self-Supervised Learning*).
    - Explicabilidad e Interpretabilidad en ML (SHAP, LIME).
    - Aprendizaje Federado y Privacidad (Privacidad Diferencial).
- **Semana 16: Presentación de Proyectos de Investigación**
    - Exposición de proyectos finales aplicados o teóricos.

Evaluación Sugerida

- **Tareas teóricas y matemáticas (20%):** Demostraciones y derivaciones formales.
- **Prácticas de código / *Labs* (20%):** Implementación desde cero (*from scratch*) de algoritmos clave (ej. SGD, SVM, XGBoost).
- **Exámenes parciales (30%):** Evaluación de conceptos teóricos y matemáticos.
- **Proyecto Final de Investigación (30%):** Desarrollo de un artículo corto (formato NeurIPS/ICML) con una contribución teórica o aplicada novedosa.

User prompt: Proporciona la bibliografía recomendada (libros de texto y papers clásicos) para este temario de posgrado.

Response: Libros de Texto Principales

- **The Elements of Statistical Learning** (2.ª ed.) — Trevor Hastie, Robert Tibshirani, Jerome Friedman.
    - *Uso en el curso:* Módulos 1, 2 y 3. El texto de referencia riguroso para la teoría del aprendizaje estadístico, regularización L1/L2, métodos de kernel y ensambles.
- **Pattern Recognition and Machine Learning** — Christopher M. Bishop.
    - *Uso en el curso:* Módulos 2 y 3. Tratamiento detallado del enfoque bayesiano, modelos gráficos probabilísticos y el algoritmo EM.
- **Understanding Machine Learning: From Theory to Algorithms** — Shai Shalev-Shwartz y Shai Ben-David.
    - *Uso en el curso:* Módulo 1. Referencia para la teoría formal de aprendizaje (PAC learning, dimensión VC y complejidad de Rademacher).
- **Deep Learning** — Ian Goodfellow, Yoshua Bengio y Aaron Courville.
    - *Uso en el curso:* Módulo 4. El estándar fundamental para las bases matemáticas y arquitecturas de aprendizaje profundo.
- **Reinforcement Learning: An Introduction** (2.ª ed.) — Richard S. Sutton y Andrew G. Barto.
    - *Uso en el curso:* Módulo 5 (Semana 14). La obra canónica para MDPs, Ecuaciones de Bellman y métodos de gradiente de política.

Papers Clásicos y Artículos de Investigación por Módulo

Módulo 1: Fundamentos y Teoría del Aprendizaje

- **A Theory of the Learnable** (1984) — Leslie Valiant.
    - *Introducción al marco formal del PAC Learning.*
- **Adam: A Method for Stochastic Optimization** (2014) — Diederik P. Kingma y Jimmy Ba.
    - *El algoritmo de optimización adaptativo de primer orden de mayor uso práctico.*

Módulo 2: Modelos Discriminativos y Generativos Clásicos

- **Regression Shrinkage and Selection via the Lasso** (1996) — Robert Tibshirani.
    - *Artículo introductorio de la regularización L1 y sparsity.*
- **Support-Vector Networks** (1995) — Corinna Cortes y Vladimir Vapnik.
    - *Formulación matemática de las Máquinas de Vectores de Soporte con margen blando.*
- **Greedy Function Approximation: A Gradient Boosting Machine** (2001) — Jerome H. Friedman.
    - *Fundamento matemático de Gradient Boosting y árboles de decisión ensamblados.*

Módulo 3: Aprendizaje No Supervisado y Probabilístico

- **Visualizing Data using t-SNE** (2008) — Laurens van der Maaten y Geoffrey Hinton.
    - *Reducción de dimensionalidad no lineal para la visualización de manifolds en alta dimensión.*
- **Maximum Likelihood from Incomplete Data via the EM Algorithm** (1977) — A. P. Dempster, N. M. Laird y D. B. Rubin.
    - *La formulación clásica y prueba de convergencia del algoritmo Expectation-Maximization.*

Módulo 4: Redes Neuronales y Aprendizaje Profundo

- **Deep Residual Learning for Image Recognition** (2016) — Kaiming He et al.
    - *Introducción de conexiones residuales (ResNets) para el entrenamiento de redes profundas.*
- **Attention Is All You Need** (2017) — Ashish Vaswani et al.
    - *Definición del mecanismo de autoatención y la arquitectura Transformer.*
- **Auto-Encoding Variational Bayes** (2013) — Diederik P. Kingma y Max Welling.
    - *Formulación teórica del Autoencoder Variacional (VAE) y el truco de reparametrización.*
- **Generative Adversarial Nets** (2014) — Ian Goodfellow et al.
    - *Modelo generativo profundo basado en la teoría de juegos minimax.*

Módulo 5: Temas Avanzados

- **Human-level control through deep reinforcement learning** (2015) — Volodymyr Mnih et al. (DeepMind).
    - *Integración de redes profundas con Q-Learning (DQN).*
- **A Unified Approach to Interpreting Model Predictions** (2017) — Scott M. Lundberg y Su-In Lee.
    - *Explicabilidad en Machine Learning mediante valores de Shapley (SHAP).*

Sources

1. PDF of The Elements of Statistical Learning - Kaggle
2. The Elements of Statistical Learning: Data Mining, Inference, and Prediction, Second Edition (Springer Series in Statistics) | Request PDF - ResearchGate
3. Deep Learning Book
4. Deep Learning by Ian Goodfellow, Yoshua Bengio, and Aaron Courville: Summary & Discussion Questions - Superbook

---

User prompt: Proporciona las guías y rúbrica para el Proyecto Final de Investigación y 2 prácticas de laboratorio tipo 'from scratch' para este curso.

Response: A continuación se presentan la guía y rúbrica para el **Proyecto Final de Investigación**, junto con dos **Prácticas de Laboratorio tipo *From Scratch*** diseñadas para un curso de Machine Learning a nivel posgrado.

1. Guía y Rúbrica del Proyecto Final de Investigación

Objetivo del Proyecto

El proyecto final tiene como objetivo que el estudiante formule, implemente y evalúe una propuesta de investigación original o una replicación/extensión rigurosa de un artículo reciente de Machine Learning (publicado en conferencias de primer nivel como NeurIPS, ICML, ICLR, AAAI, CVPR o ACL).

Estructura del Reporte (Formato NeurIPS/ICML)

El entregable final debe ser un artículo escrito en LaTeX (extensión: **6 a 8 páginas**, excluyendo referencias) con la siguiente estructura:

1. **Abstract:** Resumen ejecutivo de la contribución, metodología y hallazgos clave (máx. 250 palabras).
2. **Introduction & Related Work:** Formulación del problema, motivación, brecha en la literatura actual y trabajo previo relacionado.
3. **Methodology / Theoretical Framework:** Formulación matemática clara y rigurosa del método propuesto o analizado.
4. **Experimental Setup & Empirical Results:** Descripción de datasets, baselines, hiperparámetros, métricas de evaluación, ablaciones y análisis de sensibilidad.
5. **Discussion & Limitations:** Análisis crítico de los resultados, casos de falla y limitaciones del enfoque.
6. **Conclusion & Future Work:** Síntesis de aportaciones y trabajo futuro.

Rúbrica de Evaluación (100 Puntos Totales)

Criterio	Descripción	Puntaje
Formulación Matemática y Rigor Teórico	Claridad en la definición formal del problema, derivaciones correctas, análisis de complejidad/optimización y consistencia en la notación.	**25 pts**

Criterio	Descripción	Puntaje
Diseño Experimental y Baselines	Comparación justa contra métodos del estado del arte (*baselines*), uso de métricas adecuadas y validación estadística sólida (ej. intervalos de confianza, múltiples *seeds*).	**25 pts**
Originalidad y/o Profundidad del Análisis	Aportación novedosa o análisis crítico profundo (estudios de ablación, casos de error, impacto de hiperparámetros).	**20 pts**
Calidad del Código y Reproducibilidad	Repositorio bien documentado (GitHub/GitLab) con un `README` claro, código modular, script de entrenamiento reproducible y archivo de dependencias (`environment.yml` o `requirements.txt`).	**15 pts**
Redacción y Formato Académico	Redacción clara, figura/tablas bien estructuradas, cumplimiento del formato LaTeX estándar (NeurIPS/ICML) y referencias bien citadas.	**15 pts**

2. Prácticas de Laboratorio *From Scratch*

Práctica 1: Regresión Logística con Regularización L_1 ($Lasso$) mediante Descenso de Subgradiente e Soft-Thresholding

Objetivo

Implementar desde cero en Python (únicamente utilizando `NumPy`) un clasificador binario de Regresión Logística regularizado con la norma L_1, derivando analítica y numéricamente el operador de umbralización suave (*Soft-Thresholding Operator*).

Instrucciones de Implementación

1. **Formulación Matemática:** Dada la función de pérdida regularizada con norma L_1:

$$\mathcal{L}(\mathbf{w}) = -\frac{1}{N}\sum_{i=1}^{N}\left[y^{(i)}\log(\sigma(\mathbf{w}^T\mathbf{x}^{(i)})) + (1-y^{(i)})\log(1-\sigma(\mathbf{w}^T\mathbf{x}^{(i)}))\right] + \lambda\|\mathbf{w}\|_1$$

donde $\sigma(z) = \frac{1}{1+e^{-z}}$.

2. **Requerimientos del Código (`LogRegL1` class):**

- Implementar el algoritmo de **Desagregación/Descent por Gradiente Proximal** (*Proximal Gradient Descent*) o **Descenso por Coordenadas**.
- Definir el operador de *Soft-Thresholding*:

$$\mathcal{S}_\gamma(x) = \text{sign}(x) \cdot \max(|x| - \gamma, 0)$$

- No usar bibliotecas de Machine Learning (`scikit-learn`, `PyTorch`, `TensorFlow`).

3. **Experimentos a Entregar:**
   - Evaluar la escasez (*sparsity*) de los pesos $\mathbf{w}$ conforme aumenta $\lambda \in [10^{-4}, 10^{1}]$. Graficar el número de pesos distintos de cero vs. λ.
   - Comparar la convergencia y precisión contra la implementación estándar de `scikit-learn` (`LogisticRegression(penalty='l1', solver='liblinear')`).

Práctica 2: Máquina de Vectores de Soporte con Kernel Gaussiano (RBF-SVM) usando la Formulación Dual y Programación Cuadrática

Objetivo

Resolver la formulación dual del problema de optimización de una SVM con margen blando empleando la matriz Gram de un núcleo Gaussiano (RBF) e implementando un solver de Programación Cuadrática (mediante `scipy.optimize.minimize` o un algoritmo SMO simplificado).

Instrucciones de Implementación

1. **Formulación Dual:** Maximizar con respecto a $\boldsymbol{\alpha} = (\alpha_1, \ldots, \alpha_N)^T$:

$$\max_{\boldsymbol{\alpha}} \sum_{i=1}^{N} \alpha_i - \frac{1}{2} \sum_{i=1}^{N} \sum_{j=1}^{N} \alpha_i \alpha_j y^{(i)} y^{(j)} K(\mathbf{x}^{(i)}, \mathbf{x}^{(j)})$$

Sujeto a las restricciones:

$$0 \leq \alpha_i \leq C, \quad \forall i = 1, \ldots, N \quad \text{y} \quad \sum_{i=1}^{N} \alpha_i y^{(i)} = 0$$

Donde $K(\mathbf{x}^{(i)}, \mathbf{x}^{(j)}) = \exp\left(-\gamma \|\mathbf{x}^{(i)} - \mathbf{x}^{(j)}\|^2\right)$.

2. **Requerimientos del Código (`KernelSVM` class):**
   - Implementación de la función para calcular la **Matriz Gram** $K \in \mathbb{R}^{N \times N}$ optimizada con operaciones matriciales vectorizadas.

- Extracción de Vectores de Soporte: Identificar las muestras para las cuales $\alpha_i > 10^{-5}$.
- Cálculo del sesgo (*bias*) b utilizando las condiciones KKT (*Karush-Kuhn-Tucker*).
- Función de predicción: $\hat{y}(\mathbf{x}) = \text{sign}\left(\sum_{i \in \text{SV}} \alpha_i y^{(i)} K(\mathbf{x}^{(i)}, \mathbf{x}) + b\right)$.

3. **Experimentos a Entregar:**
   - Graficar las fronteras de decisión no lineales en un dataset sintético bidimensional (*Moons* o *Circles*) para diferentes valores de $C \in \{0.1, 1, 100\}$ y $\gamma \in \{0.01, 0.1, 1, 10\}$.
   - Identificar visualmente los vectores de soporte sobre la frontera de decisión.
